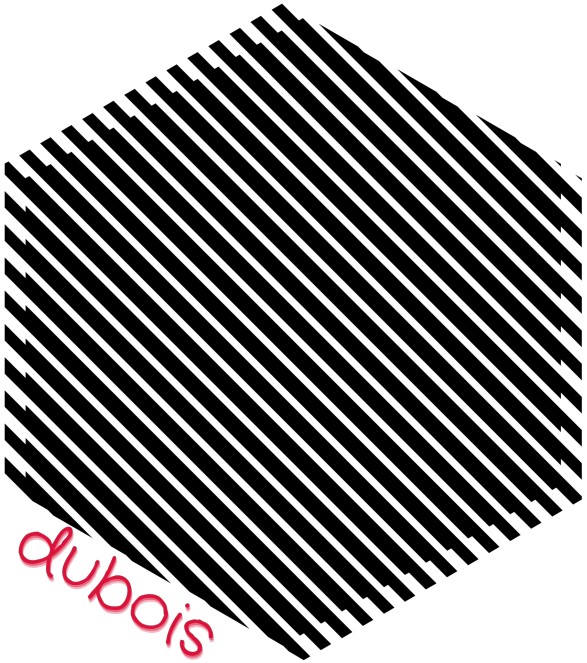

Visualização de dados através do pacote dubois

por Ícaro Bernardes

Maio de 2022

International Seminar on Statistics with R

BIT::Analytics
{Past, present and future data-driven}

Bacharelado em Eng. Química — **UFBA**

Mestrando em Eng. Industrial — **UFBA**

Co-fundador e cientista de dados — **BIT::Analytics**

Afiliação e trabalhos em *dataviz*

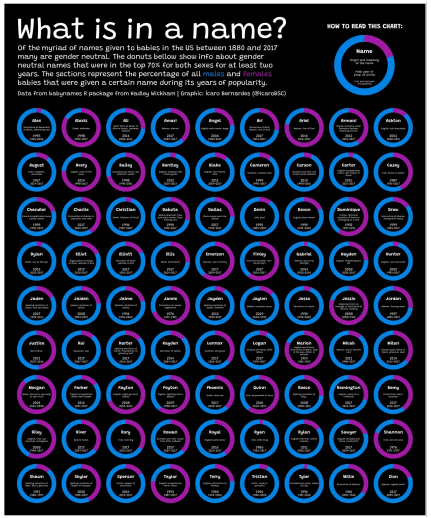

TidyTuesday

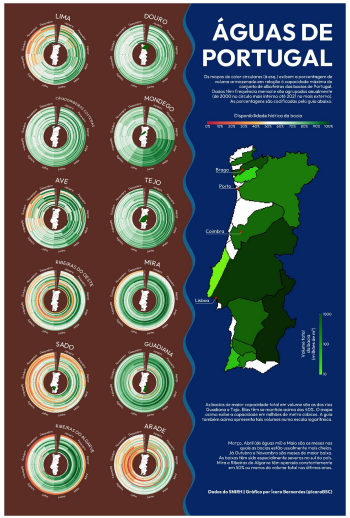

30DayChartChallenge

DuBoisChallenge

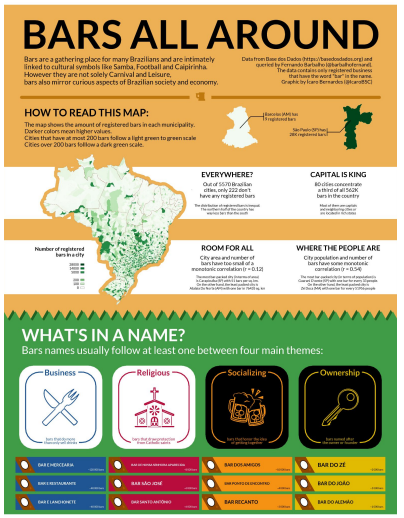

Extras

Du Bois

Sociólogo americano e
gênio do *dataviz*

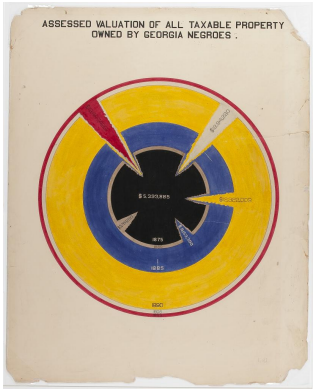

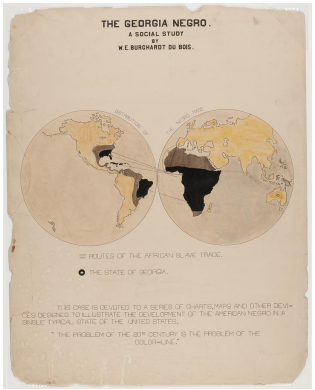

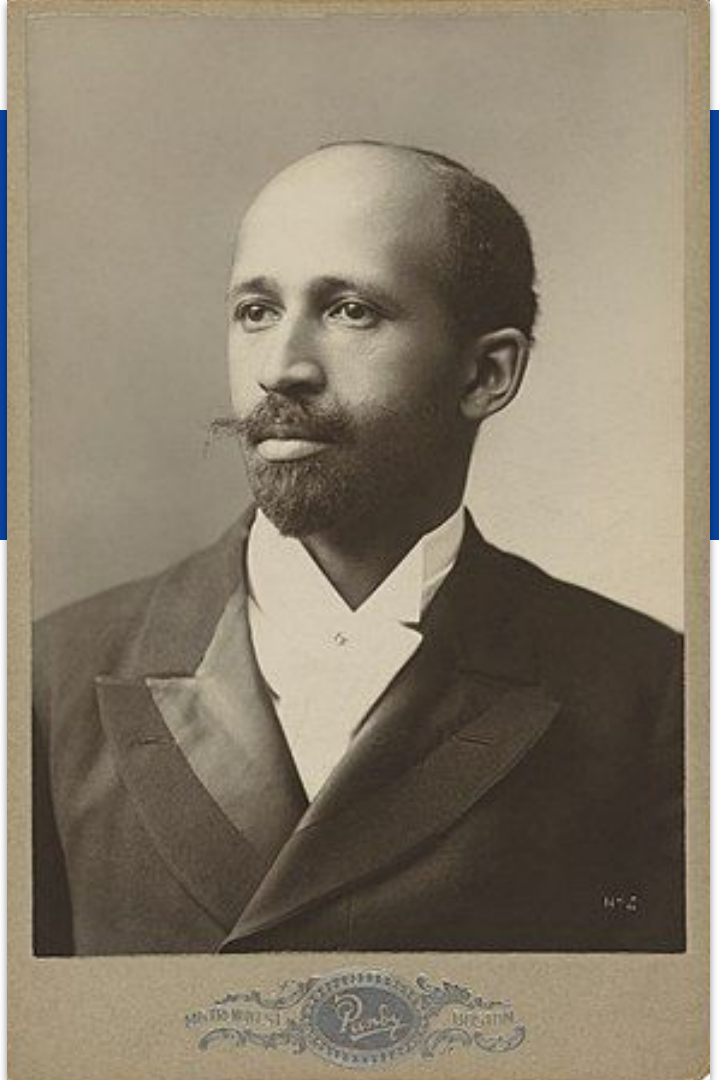

Entendendo a função
dubois::db_area

0. **Argumentos da função** (linhas 33-154)
1. **Uso de {showtext}** (linhas 156-170)
2. **Manejo dos dados** (linhas 172-302)
3. **Produção do gráfico** (linhas 304-374)

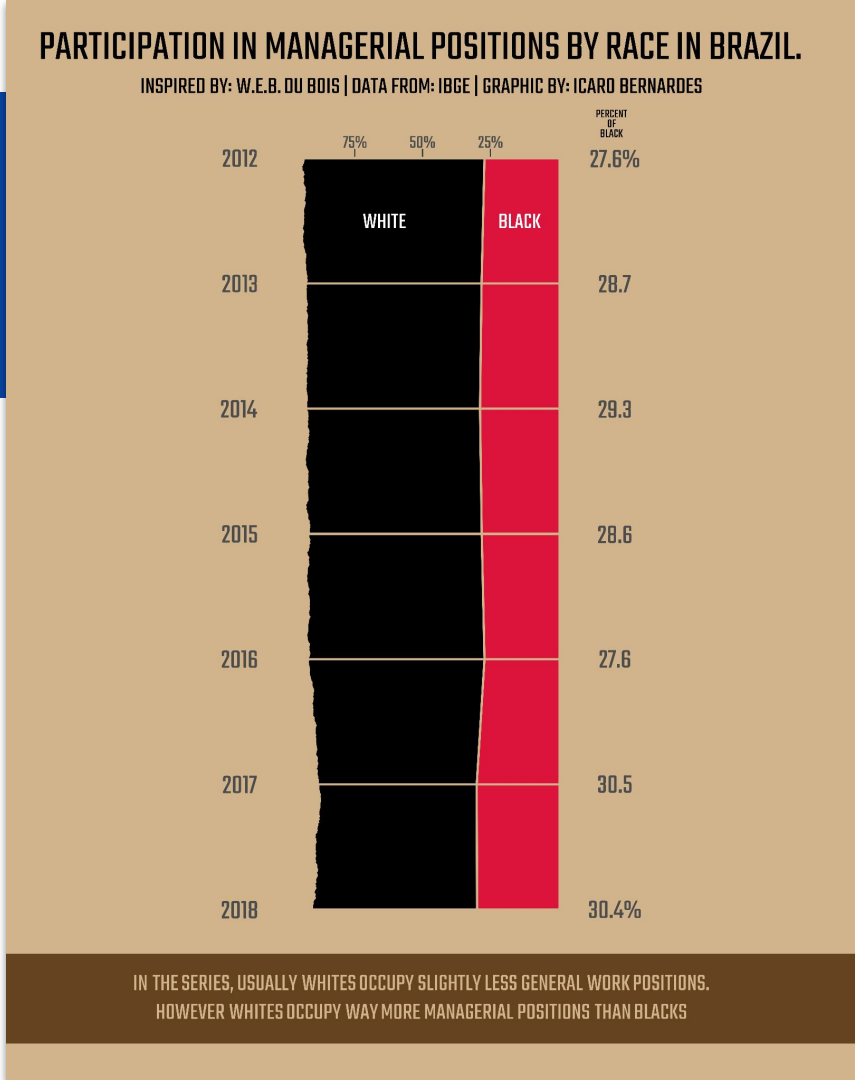

```r
# Carrega o pacote e outros auxiliares
library(dubois)

# Busca os dados sobre trabalhadores
# em cargos de comando contido no pacote
data <- dubois::managers
```

total_bosses_per_1000	total_workers_per_1000	race	year	pct_bosses_total	pct_workers_total	cv_pct_bosses
3035	92333	white	2018	68.6	45.2	1.5
3035	92333	black	2018	29.9	53.7	3.3
3294	91073	white	2017	68.0	45.9	1.4
3294	91073	black	2017	29.8	53.1	3.4
3516	90776	white	2016	71.3	46.6	1.6
3516	90776	black	2016	27.2	52.5	4.0
3650	92163	white	2015	70.3	47.2	1.2
3650	92163	black	2015	28.2	52.1	3.1
3600	91945	white	2014	69.4	47.9	1.2
3600	91945	black	2014	28.7	51.3	2.7
3450	90715	white	2013	70.1	48.1	1.1
3450	90715	black	2013	28.2	51.1	2.8
3516	90776	white	2012	71.3	46.6	1.6
3516	90776	black	2012	27.2	52.5	4.0

```r
# Carrega o pacote e outros auxiliares
library(dubois)

# Busca os dados sobre trabalhadores
# em cargos de comando contido no pacote
data <- dubois::managers

# Faz pequenas manipulações nos dados
data <- data %>%
  dplyr::select(race, year, pct_bosses_total) %>%
  tidyr::pivot_wider(names_from = "race",
                     values_from = "pct_bosses_total")

# Define título, subtítulo e mensagem
title <- "PARTICIPATION IN MANAGERIAL POSITIONS BY RACE IN
BRAZIL."
subtitle <- "INSPIRED BY: W.E.B. DU BOIS | DATA FROM: IBGE |
GRAPHIC BY: ICARO BERNARDES"
message <- "IN THE SERIES, USUALLY WHITES OCCUPY SLIGHTLY LESS
GENERAL WORK POSITIONS. HOWEVER WHITES OCCUPY WAY MORE
MANAGERIAL POSITIONS THAN BLACKS"

# Faz uso da função. A figura é
# salva no working directory
dubois::db_area(data = data, order = "year",
                cat1 = "black", cat2 = "white",
                limits = c(-3,4), # limites para o random walk
                filename = "managers.png",
                title = title, subtitle = subtitle,
                message = message)
```

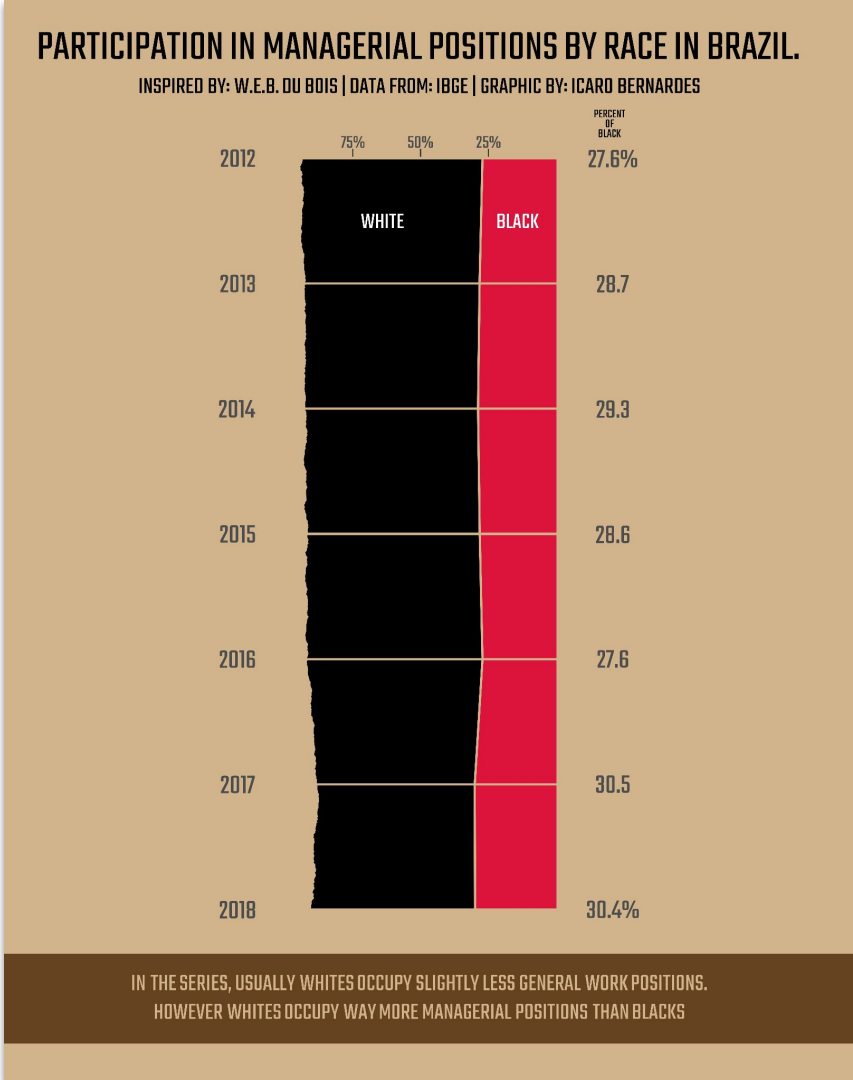

Entendendo a função
dubois::db_area

0. **Argumentos da função** (linhas 63-154)
1. **Uso de {showtext}** (linhas 156-170)
2. **Manejo dos dados** (linhas 172-302)
3. **Produção do gráfico** (linhas 304-374)

```r
# 0. Verificação inicial dos argumentos
## Confirma a classe dos argumentos
verify_class_fun <- function(arg, class) {
  sym = rlang::sym(arg)
  if (!(class %in% class(rlang::eval_tidy(sym)))) {
    stop(glue::glue("{arg} has to be a {class} or similar"), call. = FALSE)
  }
}
verify_class_data <- tibble::tibble(
  arg = c("data", "order", "cat1", "cat2",
          "dpi", "seed", "res_step", "limits",
          "names", "title", "subtitle", "message", "path", "filename"),
  class = c("data.frame", rep("character",3), rep("numeric",4), rep("character",6))
)
purrr::pwalk(verify_class_data, ~verify_class_fun(.x, .y))
```

Como é feita a verificação:

1. Uma função é criada para verificar alguma condição e parar a operação se preciso
2. Uma tibble guarda as variáveis e valores esperados para a condição ser falsa
3. purrr::pwalk aplica a função na tibble

Entendendo a função
dubois::db_area

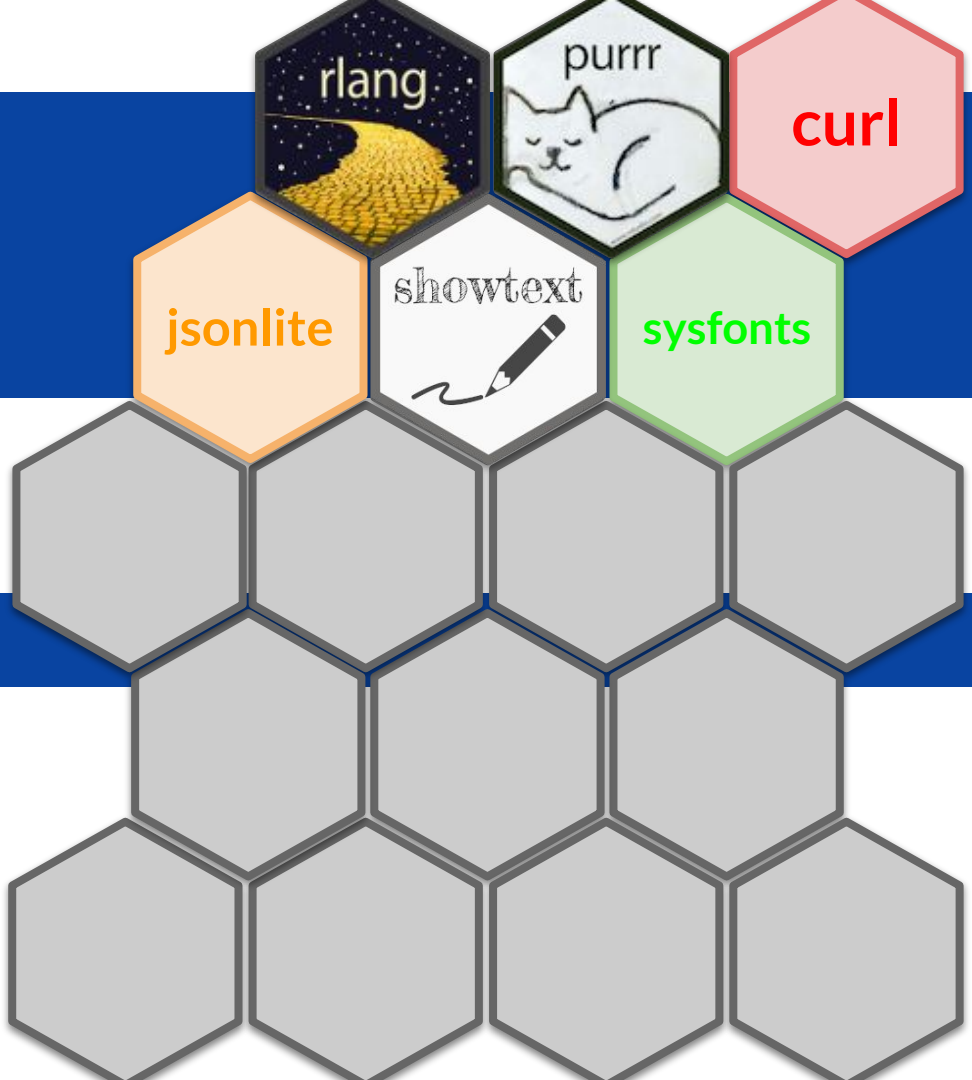

0. Argumentos da função (linhas 63-154)
1. Uso de {showtext} (linhas 156-170)
2. Manejo dos dados (linhas 172-302)
3. Produção do gráfico (linhas 304-374)

```r
# 1. Cuida da impressão do texto na imagem
## Verifica se a fonte "Teko" está disponível para ser
## usada por showtext e baixa ela se estiver ausente
if (!("Teko" %in% sysfonts::font_families())) {
  sysfonts::font_add_google(name = "Teko")
}

## Define a resolução de textos impressos por showtext nos dispositivos gráficos
showtext::showtext_opts(dpi = dpi)

## Ativa o controle da impressão do texto por parte de showtext.
## ATENÇÃO! showtext tem problemas na interalção com alguns plots
## (notadamente do pacote circlize), então é melhor criar eles
## primeiro e depois usar esse pacote
showtext::showtext_auto()
```

Como usar o {showtext}:

1. Obtenha a fonte, caso não esteja instalada em sua máquina

```r
sysfonts::font_add_google(name = "Teko")
```

2. Ative o {showtext} para que ele maneje o dispositivo gráfico

```r
showtext::showtext_auto()
```

3. Use o nome da família da fonte no argumento “family” de geom_text e afins!

```r
geom_text(family = "Teko")
```

Entendendo a função
dubois::db_area

0. **Argumentos da função** (linhas 63-154)
1. **Uso de {showtext}** (linhas 156-170)
2. **Manejo dos dados** (linhas 172-302)
3. **Produção do gráfico** (linhas 304-374)

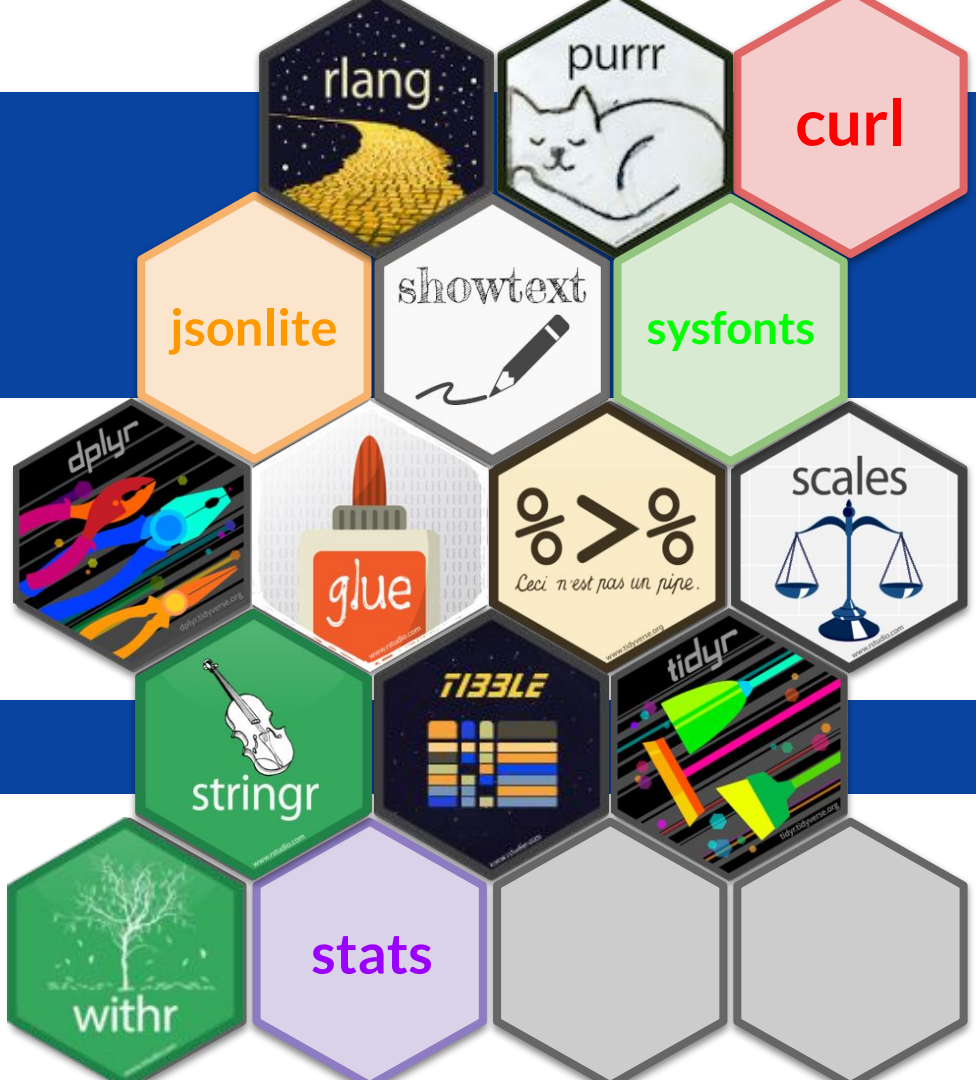

```r
# 2. Maneja os dados
## Elimina linhas com dados ausentes
data <- data %>%
  dplyr::filter(dplyr::if_all(.fns = ~ !is.na(.)))

## Obtém o número total de observações
n_obs <- dim(data)[1]

## Mantém apenas os dados da ordem das observações e os
## valores das duas categorias. Também as renomeia
data <- data %>%
  dplyr::select(order, cat1, cat2) %>%
  dplyr::rename(
    "order" = order,
    "cat1" = cat1,
    "cat2" = cat2
  )
```

```r
## Verifica se a soma do par de categorias é igual a 100%.
## Caso não seja, converte as categorias a porcentagens que o são.
check <- data %>%
  dplyr::mutate(
    pair = cat1 + cat2,
    pair == 100
  ) %>%
  dplyr::summarise(pair = sum(pair)) %>%
  dplyr::mutate(pair = (pair == n_obs)) %>%
  dplyr::pull(pair)

if (!check) {
  data <- data %>%
    dplyr::mutate(
      total = cat1 + cat2,
      cat1 = 100 * cat1 / total,
      cat2 = 100 * cat2 / total
    ) %>%
    dplyr::select(-total)
}

## Garante que a variável de ordem é ordenada. Se é um character,
## converte a factor e toma os níveis na ordem que eles aparecem
if (!is.numeric(data$order)) {
  if (!is.factor(data$order)) {
    data <- data %>%
      dplyr::mutate(order = factor(order, levels = unique(order)))
  }
}
data <- data %>% dplyr::arrange(order)
```

Ordem de elementos discretos

Pôr uma variável de classe *character* como *factor* permite escolher o ordenamento dos valores da variável na exibição no gráfico

```r
## Cria os rótulos para a categoria destacada
highlight <- data %>%
  dplyr::mutate(
    cat1 = round(cat1, digits = 1),
    cat1 = ifelse(dplyr::row_number(order) == 1L | dplyr::row_number(order) == dplyr::n(),
                  paste0(cat1, "%"),
                  cat1
    )
  ) %>%
  dplyr::pull(cat1)

## Obtém o primeiro e último itens entre as
## categorias da ordem e converte elas a números
ord1 <- data %>%
  dplyr::slice(1L) %>%
  dplyr::mutate(order = as.numeric(order)) %>%
  dplyr::pull(order)
ord2 <- data %>%
  dplyr::slice(dplyr::n()) %>%
  dplyr::mutate(order = as.numeric(order)) %>%
  dplyr::pull(order)
```

```r
## Calcula uma área à esquerda do gráfico
## usando algo como um bounded random walk
withr::local_seed(seed)
lft_area <- tibble::tibble(
  y = seq(ord1, ord2, res_step * (ord2 - ord1))
) %>%
  dplyr::rowwise() %>%
  dplyr::mutate(r = stats::rnorm(n = 1)) %>%
  dplyr::ungroup() %>%
  dplyr::mutate(
    z = cumsum(r),
    z = scales::rescale(z, to = c(limits[1], limits[2]))
  ) %>%
  dplyr::mutate(
    x = z + 2 * mean(data$cat1) / 3 + mean(data$cat2),
    x = ifelse(x > 100, 100, x)
  )
```

```r
## Define os nomes das categorias
categ_names <- data %>%
  dplyr::slice(1L:2L) %>%
  dplyr::summarise(
    x1 = mean(cat1) / 2,
    x2 = mean(cat2) / 2 + mean(cat1),
    y = mean(as.numeric(order))
  ) %>%
  tidyr::pivot_longer(
    cols = c("x1", "x2"),
    names_to = "varname",
    values_to = "x"
  ) %>%
  dplyr::select(-varname) %>%
  dplyr::mutate(label = toupper(names))
```

Funções do {ggtext}

Alternativa ao geom_text que permite pôr cor de fundo com e sem contorno, aceita algumas tags HTML e hjust e vjust como argumento dentro de aes()

```r
## Define o título, título do eixo secundário e mensagem do gráfico
title <- paste0(toupper(title), "<br><span style='font-size:60px;'>", toupper(subtitle), "</span>")
sectitle <- paste0("PERCENT<br>OF<br>", toupper(names[1]))
message <- toupper(message) %>%
  stringr::str_wrap() %>%
  stringr::str_replace_all(pattern = "\n", "<br>")
```

```r
## Define algumas constantes de layout
lnhgt <- 0.8
bgcolor <- "#d2b48c"
l_marg <- 750 - 10 * max(stringr::str_length(data$order))
lb_sz <- 60 - 2 * max(stringr::str_length(data$order))
if (lb_sz < 30) {
  lb_sz <- 30
}

## Reorganiza os dados
data <- data %>%
  tidyr::pivot_longer(
    cols = c("cat1", "cat2"),
    names_to = "categ",
    values_to = "pct"
  )

## Cria uma nova variável numérica com base na ordem
data <- data %>%
  dplyr::mutate(num_order = as.numeric(order))
```

Fonte responsiva

Um truque para criar um texto cuja fonte escala com tamanho do conteúdo é escolher famílias que sejam monoespaçadas e fazer o *font-size* inversamente proporcional ao comprimento da *string*

Entendendo a função
dubois::db_area

0. **Argumentos da função** (linhas 63-154)
1. **Uso de {showtext}** (linhas 156-170)
2. **Manejo dos dados** (linhas 172-302)
3. **Produção do gráfico** (linhas 304-374)

```r
# 3. Produção do gráfico
## Cria o gráfico
p <- data %>%
  ggplot2::ggplot() +

  ### Insere o par de áreas
  ggplot2::geom_area(ggplot2::aes(x = pct, y = num_order,
                      fill = categ),
                      orientation = "y", size = 4, color = bgcolor,
                      position = ggplot2::position_stack(reverse =
TRUE)
  ) +

  ### Insere o efeito de "rasgo" à esquerda
  ggplot2::geom_ribbon(ggplot2::aes(xmin = x, xmax = 100, y = y),
                       fill = bgcolor, data = lft_area
  )
```

geom_area

área definida entre o eixo x e valores de y (ou entre o eixo y e valores de x)

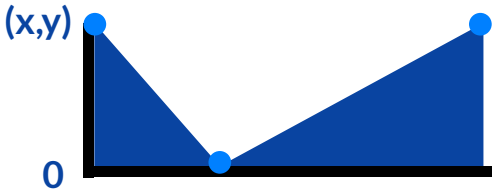

geom_ribbon

área definida entre valores máximo e mínimo de y (ou máximo e mínimo de x)

```r
# 3. Produção do gráfico
## Cria o gráfico
p <- data %>%
  ggplot2::ggplot() +

  ### Insere o par de áreas
  ggplot2::geom_area(ggplot2::aes(x = pct, y = num_order,
                      fill = categ),
                      orientation = "y", size = 4, color = bgcolor,
                      position = ggplot2::position_stack(reverse =
TRUE)
  ) +

  ### Insere o efeito de "rasgo" à esquerda
  ggplot2::geom_ribbon(ggplot2::aes(xmin = x, xmax = 100, y = y),
                       fill = bgcolor, data = lft_area
  )
```

Ordem das camadas

A ordem como as camadas (geometrias, escalas, etc) são chamadas no gráfico afeta a visualização. A ordem de "prioridade" na exibição é inversa a como as camadas são chamadas

geom_area() + geom_ribbon()

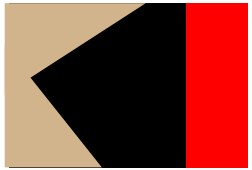

geom_ribbon() + geom_area()

```r
  ### Insere o nome das categorias
  ggplot2::geom_text(ggplot2::aes(x = x, y = y, label = label),
                     color = "white", size = 15,
                     family = "Teko", data = categ_names
  ) +

  ### Insere títulos e mensagem
  ggplot2::labs(title = title, subtitle = sectitle, caption =
message, x = NULL, y = NULL) +

 ### Reverte as escalas dos eixos e controla elementos
delas
  ggplot2::scale_x_reverse(
    expand = ggplot2::expansion(0, 10), breaks = seq(25, 75, 25),
    label = scales::label_percent(scale = 1), position = "top"
  ) +
  ggplot2::scale_y_reverse(
    expand = ggplot2::expansion(0, 0.01),
    breaks = unique(data$num_order),
    labels = unique(data$order),
    sec.axis = ggplot2::dup_axis(
      name = NULL,
      breaks = unique(data$num_order),
      labels = highlight
    )
  ) +

  ### Aplica cores definidas para as áreas
  ggplot2::scale_fill_manual(
    values = c("#dc143c", "black"),
    guide = "none"
  ) +
```

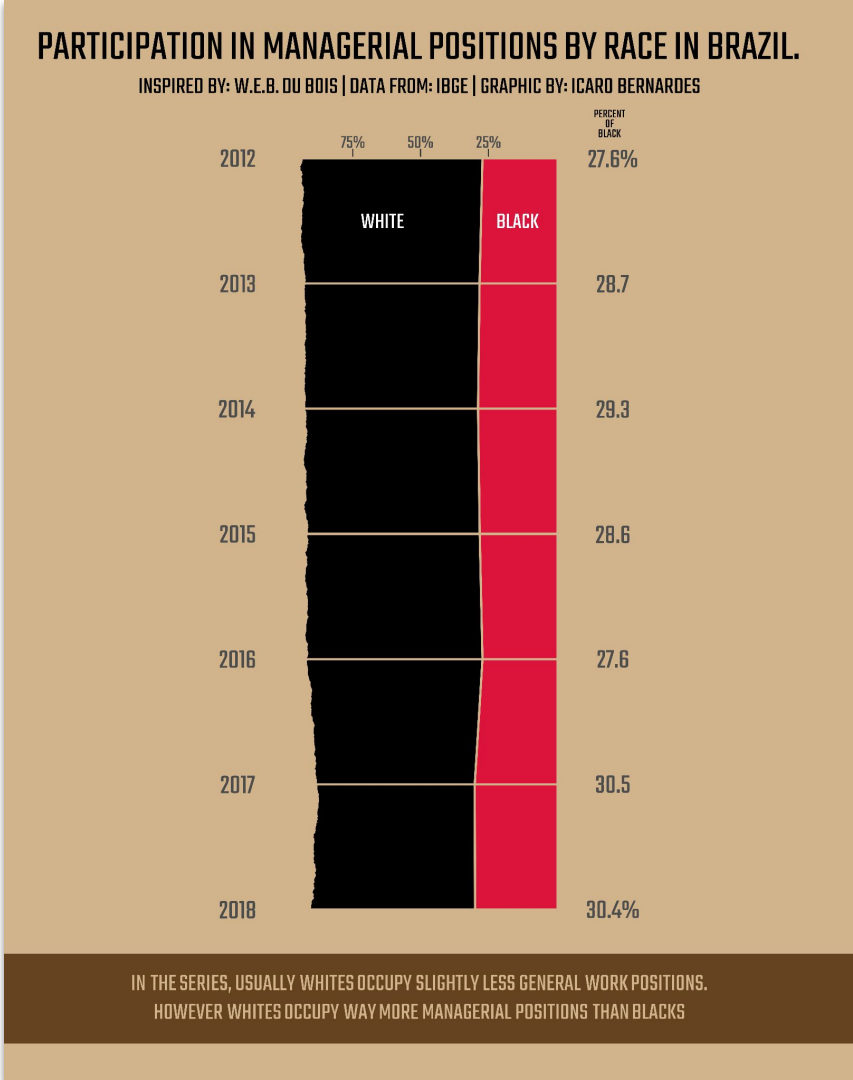

```r
### Customiza elementos do gráfico
ggplot2::theme(
  text = ggplot2::element_text(family = "Teko"),
  plot.margin = ggplot2::margin(t = 60, r = 400, b = 50, l = 400, unit =
"pt"),
  plot.background = ggplot2::element_rect(fill = bgcolor, color = NA),
  plot.title = ggtext::element_textbox_simple(
    size = 80, halign = 0.5, valign = 0.5, width = 3, lineheight = lnhgt,
    margin = ggplot2::margin(t = 0, r = 0, b = 20, l = 0, unit = "pt")
  ),
  plot.subtitle = ggtext::element_textbox_simple(
    size = 23, halign = 0.5, valign = 0.5, width = 1.5, lineheight = lnhgt,
    padding = ggplot2::margin(t = 0, r = 0, b = -10, l = l_marg, unit =
"pt")
  ),
  plot.caption = ggtext::element_textbox_simple(
    size = 45, fill = "#654321", color = bgcolor,
    halign = 0.5, valign = 0.5, width = 3,
    padding = ggplot2::margin(t = 40, r = 0, b = 40, l = 0, unit = "pt"),
    margin = ggplot2::margin(t = 80, r = 0, b = 20, l = 0, unit = "pt")
  ),
  panel.background = ggplot2::element_blank(),
  panel.grid.minor = ggplot2::element_blank(),
  panel.grid.major.x = ggplot2::element_blank(),
  panel.grid.major.y = ggplot2::element_line(color = bgcolor, size = 2),
  panel.ontop = TRUE,
  axis.text.x = ggplot2::element_text(size = 35),
  axis.text.y = ggplot2::element_text(size = lb_sz),
  axis.text.y.right = ggplot2::element_text(hjust = 0.5),
  axis.ticks.length.x = ggplot2::unit(15, "pt"),
  axis.ticks.x = ggplot2::element_line(size = 1),
  axis.ticks.y = ggplot2::element_blank()
)
```

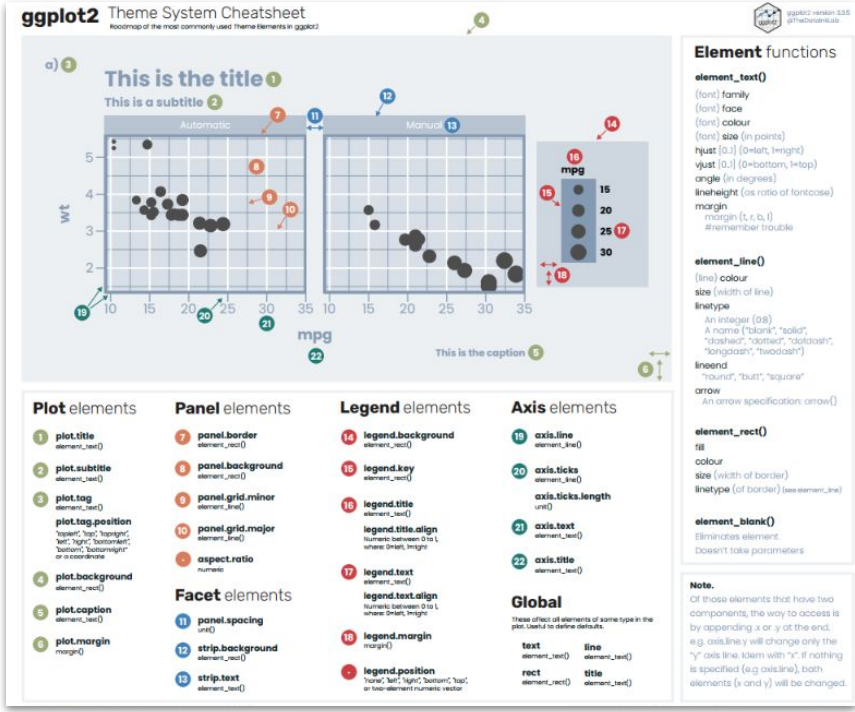

Customizar usando theme()

O Data Ink Lab fez uma excelente *cheat sheet* que indica os principais argumentos da função theme():

https://github.com/claragranell/ggplot2/blob/main/ggplot_theme_system_cheatsheet.pdf

```r
## Salva o gráfico
file <- paste0(path, "/", filename)
ggplot2::ggsave(file,
                plot = p, dpi = dpi,
                width = 22, height = 28
)
```

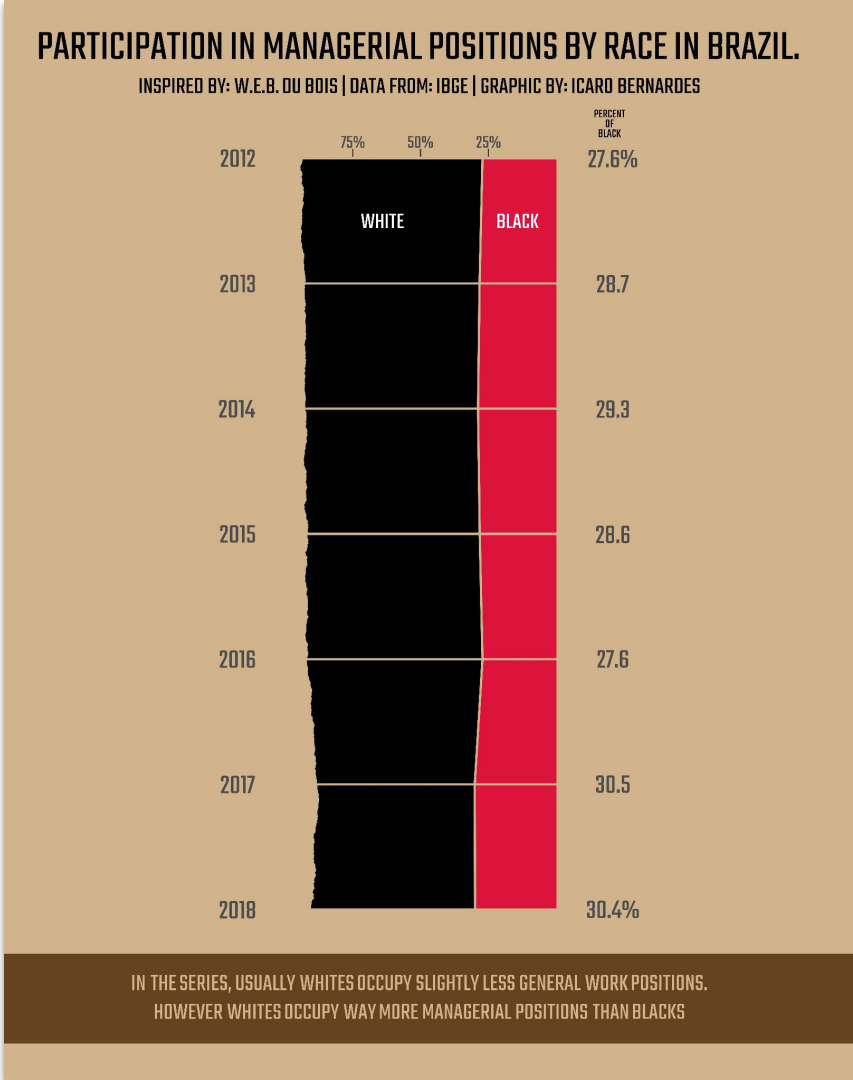

Muito obrigado!

@IcaroBSC

https://github.com/IcaroBernardes

icaro@bitanalytics.dev.br

https://www.linkedin.com/in/icarobsc